

# python 中的数据爬取

杨晨

学号 2021212171

北京邮电大学计算机学院

日期：2024 年 2 月 26 日

## 1 概述

### 1.1 实验内容

1. 爬取学堂在线的计算机类课程页面内容

<https://www.xuetangx.com/search?query=&org=&classify=1&type=&status=&page=1>

要求将课程名称、老师、所属学校和选课人数信息，保存到一个 csv 文件中。

2. 爬取链家官网二手房的数据

<https://bj.lianjia.com/ershoufang/>

要求爬取北京市东城、西城、海淀和朝阳四个城区的数据（每个区爬取 5 页），将楼盘名称、总价、平米数、单价保存到 json 文件中。

### 1.2 开发环境

- Windows10
- PyCharm 2023.2.4 (Professional Edition)

## 2 实验过程

### 2.1 学堂在线计算机类课程内容爬取

#### 2.1.1 介绍

首先，按照 PPT 上的方法，用静态页面的方式进行爬取，但是发现爬虫关闭后，也没有爬取到任何数据

考虑网页是动态加载的，进入网页审查，发现以下结果

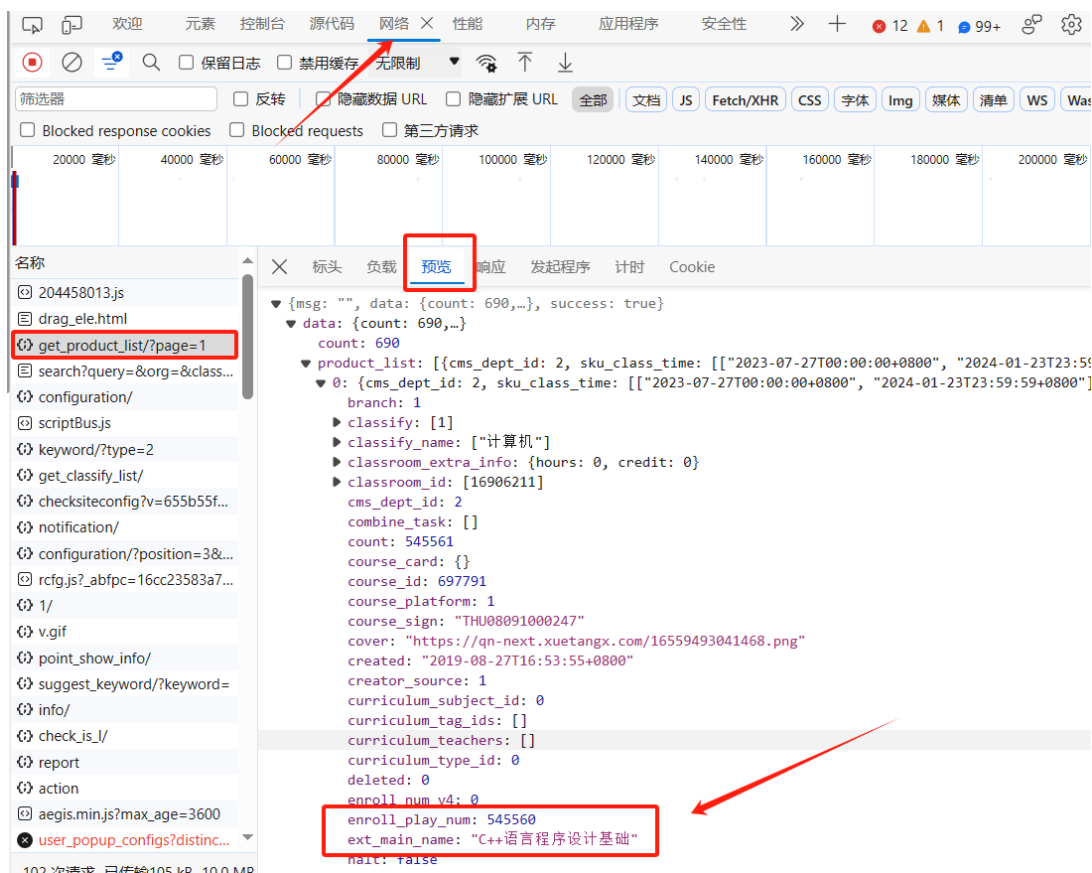
名称	状态	类型	发起程序	大小	时间	履行者	时间线
204458013.js	200	script	gzxtzx.js:7	61.9 kB	107 毫秒		
data:font/woff/base...	200	font	3.5d2cc63...css	28.2 kB	3 毫秒		
drag_ele.html	200	document		23.4 kB	76 毫秒		
get_product_list/?page=1	200	xhr	10_011c5e8...js:326	9.2 kB	336 毫秒		
search?query=&org=&cl...	200	document	其他	2.1 kB	34 毫秒		
configuration/	200	xhr	10_011c5e8...js:326	1.2 kB	36 毫秒		
scriptBus.js	200	script	scriptShell.js:10	1.2 kB	59 毫秒		
keyword/?type=2	200	xhr	10_011c5e8...js:326	1.1 kB	68 毫秒		
get_classify_list/	200	xhr	10_011c5e8...js:326	1.0 kB	250 毫秒		
checksiteconfig?v=655b5...	200	xhr	hcaptcha.js:3	998 B	1.14 秒		
notification/	200	xhr	10_011c5e8...js:326	543 B	24 毫秒		
aegis.min.js?max_age=36...	304	script	drag_ele.html:0	542 B	99 毫秒		
configuration/?position=...	200	xhr	10_011c5e8...js:326	494 B	29 毫秒		
rcfg.js?_abfpc=16cc23583...	200	script	204458013.js:2	435 B	15 毫秒		
1/	200	xhr	10_011c5e8...js:326	399 B	47 毫秒		
v.gif	200	ping	204458013.js:6	321 B	15 毫秒		
point_show_info/	200	xhr	10_011c5e8...js:326	263 B	45 毫秒		
suggest_keyword/?keywo...	200	xhr	10_011c5e8...js:326	219 B	29 毫秒		

现在明确确实是动态页面。

然后进一步发现是 Ajax 类型，以下为截图

名称	状态	类型	发起程序	大小	时间	履行者	时间线
get_product_list/?page=1	200	xhr	10_011c5e8...js:326	9.2 kB	336 毫秒		
configuration/	200	xhr	10_011c5e8...js:326	1.2 kB	36 毫秒		
keyword/?type=2	200	xhr	10_011c5e8...js:326	1.1 kB	68 毫秒		
get_classify_list/	200	xhr	10_011c5e8...js:326	1.0 kB	250 毫秒		
checksiteconfig?v=655b5...	200	xhr	hcaptcha.js:3	998 B	1.14 秒		
notification/	200	xhr	10_011c5e8...js:326	543 B	24 毫秒		
configuration/?position=...	200	xhr	10_011c5e8...js:326	494 B	29 毫秒		
1/	200	xhr	10_011c5e8...js:326	399 B	47 毫秒		
point_show_info/	200	xhr	10_011c5e8...js:326	263 B	45 毫秒		
suggest_keyword/?keywo...	200	xhr	10_011c5e8...js:326	219 B	29 毫秒		
info/	200	xhr	10_011c5e8...js:326	217 B	23 毫秒		
check_is_l/	200	xhr	10_011c5e8...js:350	213 B	21 毫秒		
report	200	xhr	janalytics iframe-web...	144 B	59 毫秒		
action	200	xhr	janalytics iframe-web...	144 B	63 毫秒		

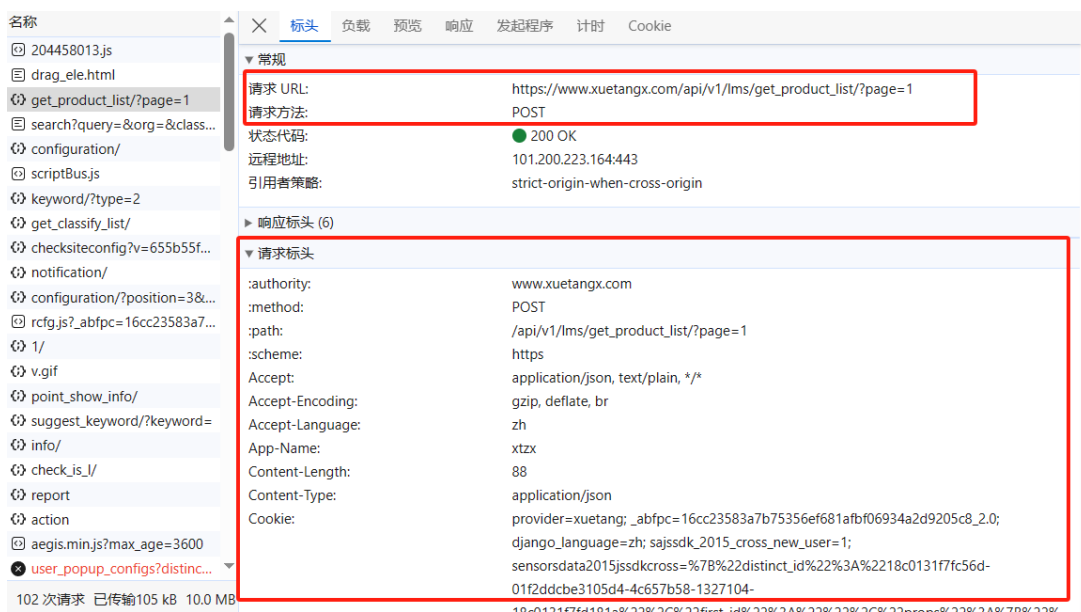
点击打开 page 里的 product\_lists 可以看见课程的相关信息，正是我们需要爬取的内容，如下所示



基于以上的发现明确进行动态页面的爬取

## 2.1.2 爬取方法

### 1. 找到爬取的链接以及请求的方式



### 2. 构造 header，找到 Headers 选项，查看请求头

### 3. 将此代码赋值下来，填充 headers 的构造，代码如下所示

```
# 请求头
headers = {
    "authority": "www.xuetangx.com",
    "method": "POST",
    "scheme": "https",
    "accept": "application/json, text/plain, */*",
    "accept-encoding": "gzip, deflate, br",
    "accept-language": "zh",
    "content-type": "application/json",
    "cookie": "provider=xuetang; django_language=zh",
    "django-language": "zh",
    "origin": "https://www.xuetangx.com",
    "Referer": "https://www.xuetangx.com/search?query=&org=&classify=1&type=&status=&page=1",
    "sec-fetch-dest": "empty",
    "sec-fetch-mode": "cors",
    "sec-fetch-site": "same-origin",
    "user-agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/119.0.0.0 Safari/537.36",
    "X-Client": "web",
    "Xtbz": "xt",
}
```

#### 4. 除了请求头此外，还需要 post 的提交表格数据



代码如下

```
data = {
    "query": "",
    "chief_org": [],
    "classify": ["1"],
    "selling_type": [],
    "status": [],
    "appid": 10000,
}
```

#### 5. 在前面第一步已经分析，采取的是 post 的页面的请求方法，那么借助FormRequest函数即可实现 post 请求。重写tart\_request(self)函数，然后经过这个函数不断的循环发送请

求，该函数代码实现如下

```
def start_requests(self):
    for page_num in range(1, 70):
        yield scrapy.FormRequest(
            url="https://www.xuetangx.com/api/v1/lms/get_product_list/?page={}"
                .format(
                    page_num
                ),
            headers=self.headers,
            method="POST",
            body=json.dumps(self.data),
            callback=self.parse,
        )
```

6. 接着就是解析内容的阶段根据我们的需求，需要爬取课程名称，老师，所属学校以及课程人数，那么将 items.py 文件如下实现：

```
class XuetangxItem(scrapy.Item):
    # 课程名称、教师、学校、学生人数
    course_name = scrapy.Field()
    teacher = scrapy.Field()
    school = scrapy.Field()
    student_num = scrapy.Field()
```

7. 那么对于 response 返回的内容，使用 json.loads 处理获取到的 json 文件，json.loads() 函数是将 json 格式数据转换为字典。网页 product\_list 部分显示如下：

```
▶ classify_name: ["计算机"]
▶ classroom_extra_info: {hours: 0, credit: 0}
▶ classroom_id: [16906211]
  cms_dept_id: 2
  combine_task: []
  count: 545561
  course_card: {}
  course_id: 697791
  course_platform: 1
  course_sign: "THU08091000247"
  cover: "https://qn-next.xuetangx.com/16559493041468.png"
  created: "2019-08-27T16:53:55+0800"
  creator_source: 1
  curriculum_subject_id: 0
  curriculum_tag_ids: []
  curriculum_teachers: []
  curriculum_type_id: 0
  deleted: 0
  enroll_num_v4: 0
  enroll_play_num: 545560
  ext_main_name: "C++语言程序设计基础"
  halt: false
  id: 4333
  is_train_valid: 0
  lecture: []
  live_status: {}
  mobile_cover: ""
  modified: "2023-11-24T02:02:26+0800"
  name: "C++语言程序设计基础"
  org: {big_logo_name: "https://qn-next.xuetangx.com/15676613232012.png", ...}
  big_logo: "https://qn-next.xuetangx.com/15675957781755.png"
```

那么对进行 product\_list 内容如下方式进行提取

```

def parse(self, response):
    for product in json.loads(response.body)["data"]["product_list"]:
        item = XuetangxItem()
        item["course_name"] = "课程名称: " + product["name"]
        item["teacher"] = "课程讲师: "
        for teacher in product["teacher"]: # 一个课程可能有多个讲师
            item["teacher"] += teacher["name"] + " "
        item["school"] = "开课学校: " + product["org"]["name"]
        item["student_num"] = "学生人数: " + str(product["count"])

```

8. 然后 pipelines 进行将数据写入 csv 文件，那么 pipelines.py 文件如下所示

```

import csv

class XuetangxPipeline:
    def __init__(self):
        self.file = open('XuetangxData.csv', 'w+', encoding='utf-8', newline='')
        self.writer = csv.writer(self.file)

    def process_item(self, item, spider):
        self.writer.writerow([item['course_name'], item['teacher'], item['school'], item['student_num']])
        return item

    def close_spider(self, spider):
        self.file.close()

```

9. 最后当然需要将管道打开，那么 settings.py 文件如下所示

```

ROBOTSTXT_OBEY = False
# ITEM_PIPELINES = {'myproject.pipelines.MyPipeline': 300}

ITEM_PIPELINES = {'myproject.pipelines.XuetangxPipeline': 300}

```

### 2.1.3 爬取结果

C1	C2	C3	C4
课程名称: 人工智能	课程讲师: 李国柱 陈子辉 赵二儿	开课学校: 北京理工大学	学生人数: 66504
课程名称: 计算机网络	课程讲师: 袁华 杜广龙 张凌	开课学校: 华南理工大学	学生人数: 67165
课程名称: 汇编语言程序设计	课程讲师: 张悠慧 霍季冬	开课学校: 清华大学	学生人数: 66496
课程名称: 学做小程序—基础篇	课程讲师: 刘强 小程序慕课讲师	开课学校: 清华大学	学生人数: 65725
课程名称: 区块链和加密数字货币	课程讲师: 罗玖	开课学校: 清华大学	学生人数: 65012
课程名称: 大学计算机教程	课程讲师: 张莉 马钦	开课学校: 中国农业大学	学生人数: 64621
课程名称: 基于Linux的C++	课程讲师: 乔林	开课学校: 清华大学	学生人数: 64397
课程名称: 大学计算机基础	课程讲师: 卫春芳	开课学校: 湖北大学	学生人数: 63085
课程名称: 数据挖掘	课程讲师: 喻梅 王蓬荣 于健 李雪威 徐天一 赵满坤 高洁 刘志强	开课学校: 天津大学	学生人数: 62514
课程名称: JAVA程序设计进阶	课程讲师: 许斌	开课学校: 清华大学	学生人数: 60880
课程名称: 物联网概论	课程讲师: 何源	开课学校: 清华大学	学生人数: 60348
课程名称: 大数据机器学习	课程讲师: 袁春	开课学校: 清华大学	学生人数: 56460
课程名称: 面向对象程序设计 (C++)	课程讲师: 曹震春 徐明星	开课学校: 清华大学	学生人数: 55728
课程名称: 微软亚洲研究院大数据系列讲座	课程讲师: 洪小文 宋睿华 谢幸 郑宇 张洪宇	开课学校: Microsoft	学生人数: 55281
课程名称: 计算几何	课程讲师: 邓俊辉	开课学校: 清华大学	学生人数: 54684
课程名称: Linux 内核分析与应用	课程讲师: 陈莉君 谢宝友 张天飞 王小根 刘露林 张丽丽	开课学校: 西安邮电大学	学生人数: 53914
课程名称: 大学计算机—计算思维的视角	课程讲师: 郝兴伟	开课学校: 山东大学	学生人数: 53777
课程名称: Python程序设计基础	课程讲师: 许志良	开课学校: 深圳信息职业技术学院	学生人数: 53616
课程名称: 网络安全概述	课程讲师: 纪平	开课学校: 纪平工作室	学生人数: 52370
课程名称: C语言程序设计 (上)	课程讲师: 李凤霞 薛静峰 陈宇峰 赵三元	开课学校: 北京理工大学	学生人数: 49979
课程名称: 数据库技术与程序设计	课程讲师: 高装装 康介敏 路明晓 程茜	开课学校: 南开大学	学生人数: 49109
课程名称: 单片机原理及应用	课程讲师: 杨恩义 魏敏 王娟丽 罗金生 王海 任震宇 向兵	开课学校: 绵阳职业技术学院	学生人数: 48806
课程名称: 大学计算机基础	课程讲师: 李敏 高装装 郭蕊 赵宏 刘哲理 路明晓 李焜 吕晓玉 宋丽	开课学校: 南开大学	学生人数: 48740
课程名称: ARM微控制器与嵌入式系统	课程讲师: 曹鸣 薛涛 黄光华	开课学校: 清华大学	学生人数: 46825
课程名称: 移动快速应用开发	课程讲师: 唐贤传 盛鸿宇 王婷婷 汤恒 胡万福	开课学校: 芜湖职业技术学院	学生人数: 44148
课程名称: Android应用开发基础	课程讲师: 鲍红 李钦 杨耿 刘志宝 任仙怡 郭敏强 蔡喜阶 纪伟传	开课学校: 深圳信息职业技术学院	学生人数: 44065

图 1: 学堂在线爬取结果

## 2.2 链家官网北京二手房数据爬取

### 2.2.1 介绍

链家的官网是静态页面，相比之下要容易处理

审查页面，找到想提取的楼盘名称、总价、平米数、单价的 xpath，进行提取即可

此外，对于第 1 页，第 2 页，网页的 url 具有相似特征/pg1，/pg2；这使得爬取较为方便

### 2.2.2 爬取方法

#### 1. 构造 spider

```
class LianjiaSpider(scrapy.spiders.Spider):
    name = "lianjia"
    allowed_domains = ["lianjia.com"]
    start_urls = [
        "https://bj.lianjia.com/ershoufang/dongcheng/pg1/",
        "https://bj.lianjia.com/ershoufang/xicheng/pg1/",
        "https://bj.lianjia.com/ershoufang/chaoyang/pg1/",
        "https://bj.lianjia.com/ershoufang/haidian/pg1/",
    ]
```

#### 2. 需要爬取的信息有：楼盘名称、总价、平米数、单价。那么 items.py 中的代码如下

```
class LianjiaItem(scrapy.Item):
    # 楼盘名称、总价、平米数、单价
    name = scrapy.Field()
    price = scrapy.Field()
    area = scrapy.Field()
```

```
unit_price = scrapy.Field()
```

### 3. 审查页面，筛选想提取的信息，如下

```
<ul class="sellListContent" log-mod="list">
  <li class="clear LOGCLICKDATA" data-lj_view_evtid="21625" data-lj_view_event="ItemExpo"
    data-lj_click_event="SearchClick" data-lj_action_source_type="链家_PC_二手列表页卡片" data-
    lj_action_click_position="0" data-lj_action_fb_expo_id="780810841238159360" data-lj_action_fb_query_id="7808108
    41208799232" data-lj_action_resblock_id="1111027380567" data-lj_action_housedel_id="101122011479">
    <a class="noresultRecommend img LOGCLICKDATA" href="https://bj.lianjia.com/ershoufang/101122011479.html"
    target="_blank" data-log_index="1" data-el="ershoufang" data-housecode="101122011479" data-is_focus data-sl>
    </a>
    <div class="info clear">
      <div class="title">
        <a class href="https://bj.lianjia.com/ershoufang/101122011479.html" target="_blank" data-log_index="1"
        data-el="ershoufang" data-housecode="101122011479" data-is_focus data-sl>新奥洋房 近地铁 满五唯一东西通透两
        居</a>
        <!-- 拆分标签 只留一个优先级最高的标签 -->
        <span class="goodhouse_tag tagBlock">必看好房</span>
        ::after
      </div>
      <div class="flood"></div>
      <div class="address">
        <div class="houseInfo"> == $0
          <span class="houseIcon"></span>
          "2室2厅 92.08平米 | 东 西 北 | 精装 | 6层 | 2006年 | 板塔结合"
        </div>
      </div>
      <div class="followInfo"></div>
      <div class="tag"></div>
      <div class="priceInfo">
        <div class="totalPrice totalPrice2"> flex
          <i></i>
          <span class="828"></span>
          <i>万</i>
        </div>
        <div class="unitPrice" data-hid="101122011479" data-rid="1111027380567" data-price="89922">
          <span>89,922元/平</span>
        </div>
      </div>
      ::after
    </div>
  <div class="listButtonContainer"></div>
```

在每个 sellListContent 类下面，每个 li 代表一个房子的信息。进行提取的代码如下

```
def parse(self, response):
    item = LianjiaItem()
    distinct = response.url.split("/") [4]
    page = response.url.split("/") [5]
    for each in response.xpath('//ul[@class="sellListContent"]/li'):
        item["name"] = "楼盘名称: " + each.xpath("div/div/a/text()").get()
        price_value = each.xpath(
            "div/div[@class='priceInfo']/div[@class='totalPrice totalPrice2']/
            span/text()"
        ).get()
        price_unit = each.xpath(
            "div/div[@class='priceInfo']/div[@class='totalPrice totalPrice2']/
            i[last()]/text()"
        ).get()
        item["price"] = "总价: " + f"{price_value}{price_unit}"
        area_text = each.xpath(
            "div[@class='address']/div[@class='houseInfo']/text()"
        ).get()
        match = re.search(r"(\d+(\.\d+)?) 平米", area_text)
```



```

if match:
    item["area"] = "平米数: " + match.group(1) + "平米"
else:
    item["area"] = "平米数: " + "unknown"
item["unit_price"] = "单价: " + each.xpath(
    "div/div[@class='priceInfo']/div[@class='unitPrice']/span/text()"
).get()
if item["name"] and item["price"] and item["area"] and item["unit_price"]:
    yield item

```

为了便于提取平米数，使用了正则表达式 re 库

4. 因为需要提取前 5 页的内容，所以需要构造下一页的 URL，并发送一个新的请求，回调函数为自身的 parse 方法，实现翻页功能

```

if page != "pg5":
    next_page = int(page[2]) + 1
    next_url = "https://bj.lianjia.com/ershoufang/{}/pg{}/".format(distinct,
        next_page)
    yield scrapy.Request(next_url, callback=self.parse)

```

5. 然后 pipelines 进行将数据写入 json 文件，那么 pipelines.py 文件如下所示

```

class LianjiaPipeline:
    def __init__(self):
        self.file = open("LianjiaData.json", "w+", encoding="utf-8")
        self.writer = csv.writer(self.file)

    def process_item(self, item, spider):
        dict_item = dict(item)
        json_str = json.dumps(dict_item, ensure_ascii=False) + "\n"
        self.file.write(json_str)
        return item

    def close_spider(self, spider):
        self.file.close()

```

6. 最后需要将管道打开，那么 settings.py 文件如下所示

```

ROBOTSTXT_OBEY = False
# ITEM_PIPELINES = {'myproject.pipelines.MyPipeline': 300}

# ITEM_PIPELINES = {'myproject.pipelines.XuetangxPipeline': 300}

ITEM_PIPELINES = {'myproject.pipelines.LianjiaPipeline': 300}

```

## 2.2.3 爬取结果

```
pipelines.py  {} LianjiaData.json x
40 {"name": "楼盘名称: 永城 莱文门 南北通透三居室 高层电梯满五年", "price": "总价: 695万", "area": "平方米: 65.29平米", "unit_price": "单价: 106,449元/"}
41 {"name": "楼盘名称: 采凤相府 花园式小区 人车分流", "price": "总价: 1250万", "area": "平方米: 96.26平米", "unit_price": "单价: 129,857元/平"}
42 {"name": "楼盘名称: 佳境胡同小区 灯市口 南北通透", "price": "总价: 590万", "area": "平方米: 52.7平米", "unit_price": "单价: 111,955元/平"}
43 {"name": "楼盘名称: 中间楼层, 采光好, 布局合理, 无浪费, 无遮挡", "price": "总价: 505万", "area": "平方米: 50.3平米", "unit_price": "单价: 100,398元/平"}
44 {"name": "楼盘名称: 清河正源三居室 明卫 精装 2层 看房随时", "price": "总价: 529万", "area": "平方米: 76.96平米", "unit_price": "单价: 68,738元/平"}
45 {"name": "楼盘名称: 茂林居 军博 近地铁 电梯南北两居 满五年", "price": "总价: 580万", "area": "平方米: 62.5平米", "unit_price": "单价: 92,800元/平"}
46 {"name": "楼盘名称: 圆明园西路3号院 2室1厅 南", "price": "总价: 490万", "area": "平方米: 55.2平米", "unit_price": "单价: 88,769元/平"}
47 {"name": "楼盘名称: 北无宿舍 精装南北两居 中间楼层 满五唯一95年", "price": "总价: 640万", "area": "平方米: 64.2平米", "unit_price": "单价: 99,689元/平"}
48 {"name": "楼盘名称: 【总监推荐】清河 永泰东里 户型方正两居 近地铁急售", "price": "总价: 438万", "area": "平方米: 73.12平米", "unit_price": "单价: 59,980元/平"}
49 {"name": "楼盘名称: 户型方正 东南 三居室 满五唯一央户 视野好 位置佳", "price": "总价: 850万", "area": "平方米: 87.35平米", "unit_price": "单价: 97,320元/平"}
50 {"name": "楼盘名称: 三成桥南路6号院 楼层好 南北通透 采光充足 居家之选", "price": "总价: 1280万", "area": "平方米: 137.38平米", "unit_price": "单价: 93,120元/平"}
51 {"name": "楼盘名称: 绿城漫板 沿河双地铁线 带电梯 高层采光 有钥匙", "price": "总价: 1789万", "area": "平方米: 164.31平米", "unit_price": "单价: 108,888元/平"}
52 {"name": "楼盘名称: 中关村 黄庄小区 电梯房 央产房 大客厅三居室", "price": "总价: 1700万", "area": "平方米: 127.1平米", "unit_price": "单价: 133,753元/平"}
53 {"name": "楼盘名称: 永金里小区 满五唯一商品房 30万精装修三居 随时可看", "price": "总价: 889万", "area": "平方米: 120.99平米", "unit_price": "单价: 73,580元/平"}
54 {"name": "楼盘名称: 田村山南路9号院 南北三居室 满五年唯一 不临街 诚意", "price": "总价: 618万", "area": "平方米: 83.71平米", "unit_price": "单价: 73,820元/平"}
55 {"name": "楼盘名称: 牡丹园 南北2居室 客厅带明窗 精装修 满五年一套诚意", "price": "总价: 625万", "area": "平方米: 62.6平米", "unit_price": "单价: 99,840元/平"}
56 {"name": "楼盘名称: 1984年底宽裕全明两居室 把边东室 随时签约", "price": "总价: 690万", "area": "平方米: 55.3平米", "unit_price": "单价: 124,774元/平"}
57 {"name": "楼盘名称: 文兴东街3号院 建筑设计院家属楼 南北通透 满5年", "price": "总价: 616万", "area": "平方米: 51.9平米", "unit_price": "单价: 118,690元/平"}
58 {"name": "楼盘名称: 新上西直门内大街 双南卧室 有电梯 随时签约", "price": "总价: 800万", "area": "平方米: 60.3平米", "unit_price": "单价: 132,678元/平"}
59 {"name": "楼盘名称: 爱民里小区 南北通透大三居 采光好 诚心出售", "price": "总价: 1328万", "area": "平方米: 96.8平米", "unit_price": "单价: 137,191元/平"}
60 {"name": "楼盘名称: 本房登记日期满五年, 业主名下只有一套住房, 户型好", "price": "总价: 1099万", "area": "平方米: 122.79平米", "unit_price": "单价: 89,510元/平"}
61 {"name": "楼盘名称: 视野好 改善大三居 观景房 客厅大 西向对着莲花河边!", "price": "总价: 1200万", "area": "平方米: 156.81平米", "unit_price": "单价: 76,525元/平"}
62 {"name": "楼盘名称: 阜成门外北四套南北通透四居室, 采光好", "price": "总价: 1330万", "area": "平方米: 121.2平米", "unit_price": "单价: 109,736元/平"}
63 {"name": "楼盘名称: 新安南里 满五年 精装修2居 可以拎包入住", "price": "总价: 575万", "area": "平方米: 58.83平米", "unit_price": "单价: 97,740元/平"}
64 {"name": "楼盘名称: 月坛北街 老业主 满五唯一 房本面积和使用面积一样大", "price": "总价: 720万", "area": "平方米: 47.4平米", "unit_price": "单价: 151,890元/平"}
65 {"name": "楼盘名称: 西城区 南北通透两居 明厨明卫 近地铁", "price": "总价: 529万", "area": "平方米: 54.71平米", "unit_price": "单价: 96,692元/平"}
66 {"name": "楼盘名称: 复兴门北大街 电梯直达 采光好", "price": "总价: 990万", "area": "平方米: 77.5平米", "unit_price": "单价: 127,742元/平"}
67 {"name": "楼盘名称: 西四 低楼层 南北通透一居室 满五年 适合贷款 诚心卖", "price": "总价: 768万", "area": "平方米: 53平米", "unit_price": "单价: 144,906元/平"}
68 {"name": "楼盘名称: 总监推荐西城鸭子桥南里南北通透3居室满五年唯一", "price": "总价: 499万", "area": "平方米: 60.39平米", "unit_price": "单价: 82,630元/平"}
69 {"name": "楼盘名称: 张仪口西里三居中间楼层大一居室", "price": "总价: 618万", "area": "平方米: 51.15平米", "unit_price": "单价: 120,822元/平"}
```

图 2: 链家爬取结果

## 3 附录: spider.py 完整代码

### 3.1 爬取学堂在线

```
import scrapy
from ..items import XuetangxItem
import json

class XuetangxSpider(scrapy.spiders.Spider):
    name = "xuetangx"
    allowed_domains = ["xuetangx.com"]
    # 请求头
    headers = {
        "authority": "www.xuetangx.com",
        "method": "POST",
        "scheme": "https",
        "accept": "application/json, text/plain, */*",
        "accept-encoding": "gzip, deflate, br",
        "accept-language": "zh",
        "content-type": "application/json",
        "cookie": "provider=xuetang; django_language=zh",
        "django-language": "zh",
        "origin": "https://www.xuetangx.com",
```

```

        "Referer": "https://www.xuetangx.com/search?query=&org=&classify=1&type=&
            status=&page=1",
        "sec-fetch-dest": "empty",
        "sec-fetch-mode": "cors",
        "sec-fetch-site": "same-origin",
        "user-agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36
            "
            "(KHTML, like Gecko) Chrome/119.0.0.0 Safari/537.36",
        "X-Client": "web",
        "Xtbz": "xt",
    }
}
data = {
    "query": "",
    "chief_org": [],
    "classify": ["1"],
    "selling_type": [],
    "status": [],
    "appid": 10000,
}
download_delay = 1

def start_requests(self):
    for page_num in range(1, 70):
        yield scrapy.FormRequest(
            url="https://www.xuetangx.com/api/v1/lms/get_product_list/?page={}"
                .format(
                    page_num
                ),
            headers=self.headers,
            method="POST",
            body=json.dumps(self.data),
            callback=self.parse,
        )

def parse(self, response):
    for product in json.loads(response.body)["data"]["product_list"]:
        item = XuetangxItem()
        item["course_name"] = "课程名称: " + product["name"]
        item["teacher"] = "课程讲师: "
        for teacher in product["teacher"]: # 一个课程可能有多个讲师
            item["teacher"] += teacher["name"] + " "
        item["school"] = "开课学校: " + product["org"]["name"]
        item["student_num"] = "学生人数: " + str(product["count"])

        if (
            item["course_name"]
            and item["teacher"]

```

```

        and item["school"]
        and item["student_num"]
    ):
        yield item

```

## 3.2 爬取链家

```

import scrapy
from ..items import LianjiaItem
import re

class LianjiaSpider(scrapy.spiders.Spider):
    name = "lianjia"
    allowed_domains = ["lianjia.com"]
    start_urls = [
        "https://bj.lianjia.com/ershoufang/dongcheng/pg1/",
        "https://bj.lianjia.com/ershoufang/xicheng/pg1/",
        "https://bj.lianjia.com/ershoufang/chaoyang/pg1/",
        "https://bj.lianjia.com/ershoufang/haidian/pg1/",
    ]

    def parse(self, response):
        item = LianjiaItem()
        distinct = response.url.split("/") [4]
        page = response.url.split("/") [5]
        for each in response.xpath('//ul[@class="sellListContent"]/li'):
            item["name"] = "楼盘名称: " + each.xpath("div/div/a/text()").get()
            price_value = each.xpath(
                "div/div[@class='priceInfo']/div[@class='totalPrice totalPrice2']/span/text()"
            ).get()
            price_unit = each.xpath(
                "div/div[@class='priceInfo']/div[@class='totalPrice totalPrice2']/i[last()]/text()"
            ).get()
            item["price"] = "总价: " + f"{price_value}{price_unit}"
            area_text = each.xpath(
                "div/div[@class='address']/div[@class='houseInfo']/text()"
            ).get()
            match = re.search(r"(\d+(\.\d+)?) 平米", area_text)
            if match:
                item["area"] = "平米数: " + match.group(1) + " 平米"
            else:
                item["area"] = "平米数: " + "unknown"
            item["unit_price"] = "单价: " + each.xpath(

```

```
        "div/div[@class='priceInfo']/div[@class='unitPrice']/span/text()"
    ).get()
    if item["name"] and item["price"] and item["area"] and item["unit_price"]
    ":
        yield item

if page != "pg5":
    next_page = int(page[2]) + 1
    next_url = "https://bj.lianjia.com/ershoufang/{}/pg{}/".format(distinct
        , next_page)
    yield scrapy.Request(next_url, callback=self.parse)
```